Μηχανική Μάθηση

Εργασία 1 – Δέντρα Απόφασης

Στόχος της εργασίας είναι η εξοικείωση με το περιβάλλον του λογισμικού **Weka**[1] και της βιβλιοθήκης της **Python Scikit-learn**[2] που εξειδικεύονται σε αλγορίθμους μηχανικής μάθησης καθώς και με την βασική πειραματική αξιολόγηση μεθόδων μηχανικής μάθησης. Για το σκοπό αυτό θα γίνει χρήση του dataset Raisin[3] και υλοποιήσεων 2 δημοφιλών αλγορίθμων δέντρων απόφασης: C4.5 και CART.

Ερωτήματα:

1. Σε ποιο πρόβλημα αναφέρεται το dataset Raisin, σε τι αποσκοπεί η μάθηση με τη χρήση του; Ποια είναι τα χαρακτηριστικά του Raisin dataset; (πλήθος/είδος attributes, τύπος target class, πλήθος παραδειγμάτων, κατανομή παραδειγμάτων σε κλάσεις κλπ.)
2. Χρησιμοποιήστε τον αλγόριθμο J48 (μετονομασία του C4.5) του Weka για να εξαχθεί ένα δέντρο απόφασης από τα δεδομένα του Raisin. Εξετάστε τις ακόλουθες παραλλαγές:
    - Χωρίς pruning
    - Με rule-based pruning
    - Με reduced-error pruning

    A. Για καθεμία από τις παραπάνω περιπτώσεις αξιολογήστε το δέντρο απόφασης χρησιμοποιώντας το 70% του dataset ως training set και το 30% ως test set. Δείξτε για καθεμία περίπτωση την αξιολόγηση της επίδοσής του με βάση το classification accuracy στο test set καθώς και το πλήθος των φύλλων του δέντρου.

    B. Για καθεμία από τις παραπάνω περιπτώσεις εφαρμόστε 10-fold cross-validation και δείξτε το classification accuracy που προκύπτει.
3. Χρησιμοποιήστε την υλοποίηση του CART[4] στην βιβλιοθήκη scikit-learn για να δημιουργήσετε ένα δέντρο απόφασης από τα δεδομένα του Raisin. Εξετάστε τις ακόλουθες παραλλαγές:
    - Χωρίς pruning και με το gini ως splitting criterion
    - Χωρίς pruning και με το entropy ως splitting criterion
    - Με pruning (χρησιμοποιώντας την τιμή υπερ-παραμέτρου a=0.1) και με το gini ως splitting criterion
    - Με pruning (χρησιμοποιώντας την τιμή υπερ-παραμέτρου a=0.1) και με το entropy ως splitting criterion

    A. Για καθεμία από τις παραπάνω περιπτώσεις αξιολογήστε το δέντρο απόφασης χρησιμοποιώντας το 70% του dataset ως Training set και το 30% ως test set. Δείξτε για καθεμία περίπτωση την αξιολόγησή της επίδοσής του με βάση το classification accuracy στο test set καθώς και το πλήθος των φύλλων του δέντρου.

    B. Για καθεμία από τις παραπάνω περιπτώσεις εφαρμόστε 10-fold cross-validation και δείξτε το classification accuracy που προκύπτει.

[1] https://www.cs.waikato.ac.nz/ml/weka/
[2] https://scikit-learn.org/
[3] https://www.muratkoklu.com/datasets/
[4] https://scikit-learn.org/stable/modules/generated/sklearn.tree.DecisionTreeClassifier.html

4. Εκτιμήστε την βέλτιστη τιμή της υπερ-παραμέτρου *α* του CART (χρησιμοποιείται για το cost-complexity pruning), όταν χρησιμοποιούμε το gini ως splitting criterion, για τις ακόλουθες περιπτώσεις:
   A. Με χρήση validation set:
      - Χωρίστε τα δεδομένα σε training, validation και test set με ποσοστό 60%-10%-30%.
      - Χρησιμοποιήστε το training set για να εκπαιδεύσετε ένα δέντρο απόφασης με τον CART και να υπολογίστε τις υποψήφιες τιμές της υπερ-παραμέτρου *α*[5].
      - Για κάθε τιμή της *α,* αναπτύξτε ένα δέντρο απόφασης με βάση το training set και αξιολογήστε το με βάση το validation set.
      - Επιλέξτε την τιμή της *α* που μεγιστοποιεί το classification accuracy στο validation set.
      - Χρησιμοποιήστε την ένωση του training set και του validation set για να εκπαιδεύσετε ένα δέντρο απόφασης με την επιλεχθείσα τιμή της *α*.
      - Αξιολογήστε το δέντρο στο test set.
   B. Χωρίς χρήση ξεχωριστού validation set:
      - Χωρίστε τα δεδομένα σε training set και test set με ποσοστό 70%-30%.
      - Χρησιμοποιήστε το training set για να εκπαιδεύσετε ένα δέντρο απόφασης με τον CART και να υπολογίστε τις υποψήφιες τιμές της υπερ-παραμέτρου *α*.
      - Για κάθε τιμή της *α,* εφαρμόστε 10-fold cross-validation στο training set και υπολογίστε το μέσο όρο του classification accuracy (για τις 10 επαναλήψεις).
      - Επιλέξτε την τιμή της *α* που μεγιστοποιεί το μέσο classification accuracy.
      - Χρησιμοποιήστε το πλήρες training set για να εκπαιδεύσετε ένα δέντρο απόφασης με την επιλεχθείσα τιμή της *α*.
      - Αξιολογήστε το δέντρο στο test set.

   Συγκρίνετε τις προσεγγίσεις Α και Β (Ποιες τιμές *α* επιλέχθηκαν; Ποια προσέγγιση είναι πιο αποτελεσματική; Ποια προσέγγιση είναι πιο γρήγορη;). Πώς συγκρίνονται τα αποτελέσματα στο test set με αυτά του ερωτήματος 3;

5. Συγκρίνετε τα αποτελέσματα που προέκυψαν από τα προηγούμενα ερωτήματα με αυτά που παρουσιάζονται στην εργασία των Cinar et al. 2020[6]. Ποιος αλγόριθμος από όσους εξετάσατε και με ποιες ρυθμίσεις είναι ο πλέον ανταγωνιστικός;

[5] https://scikit-learn.org/stable/auto_examples/tree/plot_cost_complexity_pruning.html
[6] https://dergipark.org.tr/tr/download/article-file/1227592

Οδηγίες:

Σχετικά με την εισαγωγή των δεδομένων στο Weka, χρησιμοποιήστε το αρχείο arff που συμπεριλαμβάνεται στη συλλογή δεδομένων. Στην Python συστήνεται η χρήση της βιβλιοθήκης pandas[7] για το διάβασμα του αρχείου xlsx της συλλογής δεδομένων.

Για την οπτικοποίηση του δέντρου απόφασης στην Python, υπάρχουν διάφοροι τρόποι[8].

Τι πρέπει να υποβάλλετε:

1. Μία αναφορά (PDF) που θα περιλαμβάνει τις απαντήσεις, αποτελέσματα, διαγράμματα κλπ για τα παραπάνω ερωτήματα.
2. Το κώδικα Python που χρησιμοποιήσατε για την δημιουργία των αποτελεσμάτων στα ερωτήματα 3 και 4 (συστήνεται η χρήση Jupyter Notebook[9]).

[7] https://pandas.pydata.org/
[8] https://mljar.com/blog/visualize-decision-tree/
[9] https://jupyter.org/